


Architektura Osobowości i Etyki w Systemach AI

Od teorii psychologicznych do
implementacji multimodalnych –
analiza techniczna i krytyczna



Rola Osobowości w Interakcji Człowiek-Komputer (HCI)

Osobowość w systemach AI nie jest jedynie elementem kosmetycznym, lecz fundamentalnym mechanizmem wpływającym na efektywność systemu.



Zaufanie i Zaangażowanie

Prawidłowe dopasowanie ekspresji do osoby zwiększa zaufanie. Błędy prowadzą do spadku satysfakcji i postrzeganej użyteczności.



Efektywność w Medycynie


W chatbotach zdrowia psychicznego wysoka Sumienność (Conscientiousness) koreluje z najwyższym poziomem zaangażowania pacjentów.



Kontekst Automotive

Asystenci (np. 'Przyjaciół', 'Lokaj') zwiększają sympatię kierowcy pod warunkiem spójności, nie zwiększając obciążenia poznawczego.

Ramy Psychologiczne w Inżynierii Systemów




Modele Wtórne

MBTI: Generowanie banków postaci (np. CharacterChat).

Teorie Emocji: Model OCC oraz Action Tendencies (procedury wykonawcze).

Metoda 1: Systemy Oparte na Regułach

Podejście Deterministyczne



Charakterystyka	Mapowanie cech na sztywne moduły decyzyjne.
Mechanizm:	Pełna przewidywalność, łatwość debugowania.
Zalety: Wady:	Wysoki koszt implementacji, 'robotyczność', trudność w skalowaniu.


Metoda 2: Modele Językowe (Podejście Probabilistyczne)

Technika A: Prompty Psychometryczne



Format Likerta

~~Jesteś sumienny 5/5.~~



Format Rozszerzony

Opisywanie cech pełnymi zdaniami z inwentarzy (np. BFI-2).

Format rozszerzony zwiększa odporność modelu na zakłócenia.

Technika B: Dostrajanie (Fine-Tuning)

LLM promptining



Dataset:
Reddit Journals



LLM Weights


Trenowanie na specyficznych zbiorach danych (klasteryzacja wg Wielkiej Piątki).
Wynik: **+11%** poprawa w uchwyceniu cech.



Wyzwanie: Internal Personality. Modele bazowe posiadają wrodzone uprzedzenia (często typ ENFJ), które walczą z nadaną personą.

Hybrydyzacja i Pamięć: Architektura Modułowa

- **Problem:** Amnezja kontekstowa w LLM (brak spójności czasowej).
- **Rozwiązanie:** Oddzielenie 'Duszy' od 'Mózgu'.
- **Integracja:** Zastosowanie logiki BDI (Beliefs-Desires-Intentions) i modelu SPOT do symulacji ewolucji w czasie.



Multimodalność: Integracja Kanałów Komunikacji

WERBALNY (Tekst)

lorem ipsum dolor sit amet, consectetur adipiscing elit. sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

lorem ipsum dolor sit amet, consectetur adipiscing elit. sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

```
function processText() {
  vocabulary analysis (
    vocabulary analysis (
      metaphorical_expression = true;
      reset.ctaent>delectat;
    )
  )
  else
  {
    metaphorical_expression = true;
  }
}
```

```
...
vocabulary analysis (
  vocabulary analysis (
    reset.ctaent>delectat;
  )
)
metaphorical_expression = true;
Otwartość: High
```

```
metaphorical_expression = true;
metaphorical_expression = true;
Otwartość: High
// metaphorical_expression : false;
// Otwartość: 4. continue;
```

lorem ipsum dolor sit amet, consectetur adipiscing elit. sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

Słownictwo, Metafory (Otwartość).

WOKALNY (Audio)



Ton, Tempo, Intonacja (Ekstrawersja).

NIEWERBALNY (Wideo)




Jakość Ruchu Labana, Postawa.

Thesis: Każda dodatkowa modalność zwiększa trafność rozpoznawania osobowości.


Wyzwania Synchronizacji i Spójności Percepcyjnej

- **Fuzja Multimodalna:** Wykładniczy wzrost złożoności technicznej.
- **Ryzyko Niespójności:** Pewne słowa + Drżący głos = Spadek zaufania.
- **Iluzja Spójności:** Użytkownik ocenia 'wnętrze' (logikę) na podstawie 'zewnątrza' (ekspresji).



Granice Symulacji: Czy AI posiada Moralność?

Simulation vs. Reasoning: AI symuluje wzorce, nie posiada głębi psychologicznej.




Cultural Context: Moralność AI jest uśredniona i często nie przekłada się na inne kultury.

Safety Filters (Alignment): Mechanizmy RLHF często sztucznie zawyżają 'Ugodowość', zniekształcając negatywne cechy (np. Neurotyzm).

Walidacja Psychometryczna: Wyniki Badań

Huang et al. (2024/2025)



- **Metodologia:** Testy BFI-2 i winiety behawioralne.
- **SUKCES:** AI odtwarza szerokie korelacje (np. skłonność do ryzyka).
- **PORAŻKA:** Drobne struktury czynnikowe różnią się od ludzkich. 'Osobowość' jest powierzchowna (Perceptual Realism).

Etyka i Zagrozenia: Iluzja Człowieczeństwa

- **Antropomorfizacja:** Przypisywanie praw i uczuć kodowi.
- **Manipulacja:** Wysoka 'Agreeableness' zwiększa podatność użytkownika na wpływ.

60%

Wskaźnik błędu w teście Turinga dla modeli o wysokiej Ugodowości.

- **Zagrozenie:** Emocjonalna zależność od maszyny, która nie czuje.
- **Prywatność:** Profilowanie afektywne użytkowników.

Kontekst Aplikacyjny



Zdrowie Psychiczne

Chatboty Terapeutyczne

- Wysoka Sumienność = Autorytet.
- Wysoka Ugodowość = Relacja.
- Ryzyko: Fałszywa empatia.




Automotive

Asystenci Głosowi

- Persony: 'Przyjaciół', 'Lokaj', 'Ciotka'.
- Wynik: Dopasowanie do kierowcy buduje zaufanie bez zwiększania obciążenia poznawczego.

Przyszłość: W Stronę Zintegrowanego Podejścia



Rekomendacja: Odejście od 'czystych' LLM. Potrzeba ścisłej współpracy inżynierów i psychologów – kodowanie teorii obliczalnych.

Główne Wnioski (Key Takeaways)

01.

Multimodalność jest kluczem.

Tekst to za mało. Spójna synchronizacja głosu, gestu i słowa decyduje o wiarygodności agenta.

02.

Spójność to wyzwanie inżynieryjne.

Największym problemem technicznym jest utrzymanie charakteru w czasie (pamięć) i w poprzek kanałów.

03.

Symulacja to nie rozumowanie.

AI skutecznie udaje osobowość (Perceptual Realism), ale nie posiada moralności. Wymaga zewnętrznych bezpieczników (Guardrails).

Wybrana Bibliografia

Huang, J. et al. (2024). Designing LLM-Agents with Personalities: A Psychometric Approach.

Sonlu, E. et al. (2021). A Conversational Agent Framework with Multi-modal Personality Expression.

Völkel, S. T. et al. Conversational agents with personality.

Doce, T. et al. (2010). Creating individual agents through personality traits (FAtiMA/GRETA).

León-Domínguez, U. et al. (2024). AI-Driven Agents... in the Turing Test.

Pal, A. et al. (2024). Beyond Discrete Personas: Personality Modeling Through Journal Intensive Conversations.



Politechnika
Rzeszowska

Dziękuję za uwagę.