

NAWIGACJA ROBOTÓW HUMANOIDALNYCH

WYKŁAD 3

Planowanie ruchu i unikanie przeszkód

dr inż. Mateusz Pomianek



Planowanie globalne

Planowanie lokalne

Footstep planning

Kody Python

Plan wykładu

Sekcja 1

Planowanie globalne: przestrzeń stanów, Dijkstra, A*, heurystyki, cost map, wygładzanie

Sekcja 2

Planowanie lokalne: DWA, potential fields, MPC, przeszkody dynamiczne, replanowanie

Sekcja 3

Footstep planning: sekwencja kroków, ograniczenia kinematyczne, schody, trajektoria CoM

Kody Python

A* na grid map, A* z cost map, pole potencjału, ocena trajektorii, generacja kroków

01

SEKCJA

Planowanie globalne

Reprezentacje środowiska, Dijkstra, A, heurystyki i cost map*



Miejsce planowania w architekturze systemu

Wejście: mapa + lokalizacja

Planista dostaje mapę kosztów i bieżącą pozycję robota z estymatora stanu

Wejście: cel misji

Punkt docelowy lub sekwencja celów pośrednich z modułu zarządzania misją

Wyjście: ścieżka globalna

Ciąg punktów w przestrzeni (x,y) lub (x,y,z) przekazywany do planisty lokalnego

Wyjście: cost map

Mapa kosztów przesyłana do lokalnego planisty jako mapa naviagacyjna

Problem planowania ścieżki

- **Przestrzeń stanów:** zbiór wszystkich dopuszczalnych konfiguracji robota $C_{\text{free}} \subseteq C$
 - **Stan początkowy q_{start} :** aktualna pozycja i orientacja robota w mapie
 - **Stan docelowy q_{goal} :** żądana pozycja końcowa misji
- **Ograniczenia:** przeszkody, granice mapy, kinematyka, stabilność robota
- **Funkcja kosztu:** $c(q_{\text{start}}, q_{\text{goal}})$ minimalizowana wzdłuż ścieżki (czas, energia, ryzyko)
- **Ścieżka optymalna:** ciąg $\gamma : [0,1] \rightarrow C_{\text{free}}$ taki, że $\gamma(0)=q_{\text{start}}, \gamma(1)=q_{\text{goal}}$
- **Zupełność:** algorytm znajdzie ścieżkę, jeśli istnieje; optymalność: znajdzie najlepszą

Reprezentacje grafowe środowiska

Siatka komórek (Grid)

- Regularna siatka $N \times M$ komórek
- Komórka: wolna / zajęta / koszt
- Łatwa implementacja A*
- Duże mapy = wysoka pamięć
- Rozdzielczość ogranicza precyzję

Graf topologiczny

- Węzły = charakterystyczne miejsca
- Krawędzie = przejazdy między nimi
- Szybkie planowanie wysokopoziomowe
- Niska rozdzielczość geometryczna
- Wymaga mapowania semantycznego

Visibility/Roadmap

- Graf widzialności krawędzi przeszkód
- Trasy wzdłuż wklętości przeszkód
- Optymalne w 2D dla znanych map
- Trudne do uogólnienia na 3D
- Rzadko stosowane dla humanoida

Algorytm Dijkstry

Pseudokod Dijkstry

```
1. dist[start] = 0; dist[v] = ∞ dla pozostałych
2. priority_queue Q: (dist, vertex)
3. Q.push((0, start))
4. while Q nie jest pusta:
5.     (d, u) = Q.pop_min()
6.     if d > dist[u]: continue
7.     for (v, w) in sąsiedzi(u):
8.         nowy_koszt = dist[u] + w
9.         if nowy_koszt < dist[v]:
10.            dist[v] = nowy_koszt
11.            poprzednik[v] = u
12.            Q.push((nowy_koszt, v))
13. odtwórz ścieżkę przez poprzednik[]
```

Właściwości

- Gwarantuje optymalność
- Brak heurystyki, eksploruje we wszystkich kierunkach
- Złożoność: $O((V+E) \log V)$
- Wolny dla dużych map
- Dobry jako punkt odniesienia
- Podstawa A* i Bellmana-Forda

Algorytm A* - planowanie z heurystyką

Pseudokod A*

$f(n) = g(n) + h(n)$

$g(n)$ - koszt dotarcia od startu do n

$h(n)$ - heurystyka: szacunek do celu

```
1. open_set = {start}
2. g[start] = 0; f[start] = h(start)
3. while open_set nie jest pusta:
4.     u = węzeł z min f w open_set
5.     if u == goal: odtwórz ścieżkę
6.     open_set.remove(u)
7.     for v in sąsiedzi(u):
8.         tentative_g = g[u] + cost(u,v)
9.         if tentative_g < g[v]:
10.            g[v] = tentative_g
11.            f[v] = g[v] + h(v)
12.            parent[v] = u
```

Właściwości

- Optymalny gdy h admissible
- Szybszy od Dijkstry dzięki h
- h euklidesowa: $\sqrt{dx^2+dy^2}$
- h Manhattan: $|dx|+|dy|$
- Im lepsza h , tym mniej węzłów
- Złożoność: $O(b^d)$, b =branching

A* na mapie zajętości (grid map)

```
import heapq, numpy as np

def astar(grid, start, goal):
    """A* na siatce 2D. grid[r][c]=0: wolne, 1: zajete."""
    rows, cols = grid.shape
    h = lambda r, c: abs(r-goal[0]) + abs(c-goal[1])
    g = {start: 0}
    parent = {start: None}
    pq = [(h(*start), start)]
    while pq:
        _, u = heapq.heappop(pq)
        if u == goal:
            path = []
            while u:
                path.append(u)
                u = parent[u]
            return path[::-1]
        for dr, dc in [(-1,0), (1,0), (0,-1), (0,1)]:
            v = (u[0]+dr, u[1]+dc)
            if 0<=v[0]<rows and 0<=v[1]<cols and grid[v]==0:
                ng = g[u] + 1
                if ng < g.get(v, 1e9):
                    g[v]=ng; parent[v]=u
                    heapq.heappush(pq, (ng+h(*v), v))
```

Opis: Manhattan h – dopuszczalna i spójna; 4-kierunkowa sąsiedztwo; zwraca listę komórek ścieżki

Właściwości i zastosowanie Heurystyki w A*

Heurystyka Manhattan (L1)

- $h(n) = |dx| + |dy|$
- Idealna dla siatek z ruchem 4-kierunkowym
- Dopuszczalna: nigdy nie przeszacowuje kosztu
- Bardzo szybka – prosta operacja arytmetyczna
- Dla ruchu 8-kierunkowego: lekko nieprecyzyjna

Heurystyka euklidesowa (L2)

- $h(n) = \sqrt{dx^2 + dy^2}$
- Odpowiednia dla ciągłego ruchu w 2D/3D
- Dopuszczalna dla humanoida (metryczny koszt)
- Droższa obliczeniowo (sqrt), lecz precyzyjniejsza
- Zalecana gdy ścieżka jest wygładzana

Planowanie z uwzględnieniem kosztów terenu

- **Cost map** zastępuje binarną mapę wolne/zajęte gradientem kosztów
- **Cel**: preferowanie bezpiecznych, szerokich przejść zamiast najkrótszej trasy geometrycznej
- **Warstwy kosztu**: inflacja wokół przeszkód, nachylenie terenu, wskaźnik stabilności, gęstość ruchu
- **Implementacja**: komórki siatki mają wartość $c \in [0, 255]$; A* używa $\text{cost}(u,v) = 1 + c(v)/50$
- **Efekt**: trasa omija obrzeża mebli i wąskie przejścia nawet gdy są geometrycznie wolne
- **Dynamiczna aktualizacja**: nowe obserwacje LiDAR/kamery zmieniają cost map online
- **Parametryzacja**: wagi warstw dobierane eksperymentalnie lub przez uczenie maszynowe

A* z mapą kosztów terenu

```
import heapq, numpy as np

def astar_cost(grid, cost_map, start, goal):
    """A* z kosztem komórki z cost_map [0-100]."""
    rows, cols = grid.shape
    h = lambda r, c: np.hypot(r-goal[0], c-goal[1]) # euklidesowa
    g = {start: 0.0}
    parent = {start: None}
    pq = [(h(*start), start)]
    while pq:
        _, u = heapq.heappop(pq)
        if u == goal:
            path, node = [], u
            while node: path.append(node); node = parent[node]
            return path[::-1]
        for dr, dc in [(-1,0),(1,0),(0,-1),(0,1),(-1,-1),(1,1),(-1,1),(1,-1)]:
            v = (u[0]+dr, u[1]+dc)
            if 0<=v[0]<rows and 0<=v[1]<cols and grid[v]==0:
                step = np.hypot(dr,dc) * (1 + cost_map[v]/50.0)
                if (ng := g[u]+step) < g.get(v,1e9):
                    g[v]=ng; parent[v]=u
                    heapq.heappush(pq, (ng+h(*v),v))
```

Opis: 8-kierunkowe sąsiedztwo; koszt przejścia = odległość * (1 + wartość_kosztu/50); ruch po skosie droższy

Wygładzanie ścieżki globalnej

- A^* na siatce zwraca ścieżkę z ostrymi załamaniami przy każdej zmianie kierunku
- **Wygładzanie:** konieczne przed przekazaniem ścieżki do generatora kroków lub MPC
- **Metoda 1, interpolacja B-spline:** krzywa przechodzi blisko punktów kontrolnych, zachowuje ciągłość krzywizny
- **Metoda 2, skracanie (shortcutting):** iteracyjne usuwanie pośrednich punktów, jeśli prosta jest wolna od przeszkód
- **Metoda 3, filtr Gaussa 1D:** ważona średnia po sąsiednich punktach wzdłuż ścieżki
- **Metryka:** kąt ugięcia $< 15^\circ$ między kolejnymi odcinkami jako warunek akceptacji
- **Ważne:** wygładzona ścieżka musi pozostawać w wolnej przestrzeni – weryfikacja kolizji po wygładzeniu

02

SEKCJA

Planowanie lokalne i unikanie przeszkód

DWA, potential fields, MPC, przeszkody dynamiczne



Po co potrzebny planista lokalny?

Świat dynamiczny

Mapa globalna nie uwzględnia ludzi, wózków, otwieranych drzwi. Planista lokalny reaguje na bieżąco

Niedoskonała mapa

Sensory mają szum, mapa jest zbudowana ze starego skanu – lokalna mapa jest zawsze świeższa

Ograniczenia dynamiki

Robot nie może skręcić dowolnie ostro ani zatrzymać się natychmiast – kinematyka musi być uwzględniona

Horyzont predykcji

Decyzje na 1–3 s do przodu wystarczają; pełny replan jest zbyt kosztowny w każdym cyklu (10–50 Hz)

Pola potencjału (Potential Fields)

Wzory sił

$U_{\text{attr}}(q) = \frac{1}{2} \cdot k_{\text{att}} \cdot d^2(q, q_{\text{goal}})$
- atrakcja do celu; rośnie z odległością

$U_{\text{rep}}(q) = \frac{1}{2} \cdot k_{\text{rep}} \cdot (1/d - 1/d_0)^2$
gdy $d < d_0$, inaczej 0 - odpychanie od przeszkód
 d_0 - promień wpływu przeszkody

$F(q) = -\nabla U(q)$
 $= F_{\text{attr}} + F_{\text{rep}}$

Ruch: $q_{\text{new}} = q + \alpha \cdot F(q)$
 α - krok iteracji

Właściwości

- Prosta implementacja
- Działa w czasie rzeczywistym
- Problem: minima lokalne
- Oscylacje w wąskich przejściach
- Trudna parametryzacja k_{att} , k_{rep}
- Rozwiązanie: potencjały harmoniczne lub RRT

Idea Dynamic Window Approach (DWA)

- **Idea:** w każdym kroku czasowym szukaj najlepszej pary prędkości (v, ω) z okna osiągalnego
- **Okno dynamiczne:** $\{(v, \omega) \mid v \in [v_{-a_max} \cdot dt, v_{+a_max} \cdot dt], \omega \text{ analogicznie}\}$
- **Ocena trajektorii:** dla każdego kandydata (v, ω) symuluj ruch przez T sekund (np. $T=2$ s)
- **Funkcja celu:** $G(v, \omega) = \alpha \cdot \text{heading} + \beta \cdot \text{clearance} + \gamma \cdot \text{velocity}$
- **heading:** wyrównanie kierunku ruchu z celem globalnym
- **clearance:** odległość od najbliższej przeszkody wzdłuż trajektorii
- **velocity:** nagroda za wyższą prędkość do przodu
- **wybierz $(v^*, \omega^*) = \operatorname{argmax} G$** – wykonaj jeden krok, przelicz w kolejnym cyklu

Model Predictive Control, czyli taka „intuicja”

- **MPC** optymalizuje sekwencję sterowań $u_0, u_1, \dots, u_{N-1}$ na horyzoncie N kroków
- **Model predykcji**: $x_{t+1} = f(x_t, u_t)$ – uproszczony model kinematyczny/dynamiczny robota
- **Funkcja celu**: minimalizacja odchylenia od ścieżki + kosztu sterowania + penalizacja za przeszkody
- **Ograniczenia**: $|v| \leq v_{\max}$, $|\omega| \leq \omega_{\max}$, brak kolizji, stabilność ZMP
- **Receding horizon**: po wyznaczeniu sekwencji wykonuje się tylko u_0 , a plan jest aktualizowany
- **Zalety**: jawne ograniczenia dynamiczne, optymalne zarządzanie kolizjami w horyzoncie
- **Wada**: wysoki koszt obliczeniowy (solver QP/NLP); wymaga dedykowanego CPU lub GPU

Pole potencjału - lokalny wektor ruchu

```
import numpy as np

def potential_field_move(robot_pos, goal_pos, obstacles,
                        k_att=1.0, k_rep=100.0, d0=1.5):
    """Wyznacza wektor ruchu z pol potencjalnych."""
    robot = np.array(robot_pos, dtype=float)
    goal = np.array(goal_pos, dtype=float)
    # Sila atrakcji do celu
    f_att = k_att * (goal - robot)
    # Suma sil odpychania od przeszkód
    f_rep = np.zeros(2)
    for obs in obstacles:
        diff = robot - np.array(obs)
        d = np.linalg.norm(diff) + 1e-6
        if d < d0:
            f_rep += k_rep * (1/d - 1/d0) * diff / d**3
    total = f_att + f_rep
    return total / (np.linalg.norm(total) + 1e-6) # wektor jednostkowy
```

Opis: Zwraca znormalizowany wektor ruchu; mnożymy przez Δt i prędkość robota, by uzyskać przemieszczenie

Ocena kandydatów trajektorii (uproszczone DWA)

```
import numpy as np

def score_trajectory(v, omega, robot_state, goal, obstacles,
                    T=2.0, dt=0.1,
                    alpha=0.4, beta=0.4, gamma=0.2):
    """Ocenia trajektorie (v, omega) w horyzoncie T sekund."""
    x, y, yaw = robot_state
    min_clearance = 1e9
    for _ in range(int(T / dt)):
        x += v * np.cos(yaw) * dt
        y += v * np.sin(yaw) * dt
        yaw += omega * dt
        for obs in obstacles:
            min_clearance = min(min_clearance, np.hypot(x-obs[0], y-obs[1]))
    heading = -abs(np.arctan2(goal[1]-y, goal[0]-x) - yaw)
    clearance = min_clearance
    return alpha*heading + beta*clearance + gamma*v
```

Opis: Wyższy score = lepsza trajektoria; wywoływane dla N par (v, ω) , wybierana para z max score

Unikanie ludzi i przeszkód dynamicznych

Detekcja i predykcja

- **Detekcja ludzi:** YOLO, PointNet na chmurze LiDAR
- **Śledzenie** (tracking): filtr Kalmana per obiekt
- **Predykcja:** stałe velocity, Social Force Model
- **Horyzont predykcji:** 1–3 s wystarczy
- **Niepewność:** elipsa kowariancji wokół ścieżki

Planowanie z uwzględnieniem ruchu

- **Strefa bezpieczeństwa:** okrąg lub elipsa wokół człowieka
- **Prędkość** przeszkody skaluje rozmiar strefy
- **ORCA** (Optimal Reciprocal Collision Avoidance)
- **Social navigation:** min. 1,2 m od człowieka
- Zatrzymanie gdy człowiek zbliży się $< 0,5$ m

Kiedy i jak przeplanowywać online

Replan globalny (rzadki)

- Gdy cel misji zostaje zmieniony
- Gdy mapa zasadniczo się zmienia (*zamknięte przejście*)
- Co 5–30 sekund lub na żądanie operatora
- Kosztowny obliczeniowo – całkowite A*
- Alternatywa: D* Lite (*przyrostowy A**)

Replan lokalny (częsty)

- Co 50–100 ms w każdym cyklu planisty
- Okno lokalne wokół bieżącej pozycji robota
- Reaguje na nowe przeszkody dynamiczne
- Możliwy na CPU embarked 1–2 ms
- Brak zmiany ścieżki globalnej

Konflikt między planem, a stabilnością

- **Problem:** optymalny manewr unikania może wymagać szybkiego skrętu lub dużej prędkości bocznej
- **Konsekwencja:** środek masy wychodzi poza wielobok podparcia → utrata równowagi
- **Reguła nadrzędna:** stabilność > unikanie kolizji > optymalizacja trasy
- **Implementacja:** każda kandydatka trajektoria lokalnej jest filtrowana przez weryfikator ZMP
- **Weryfikator ZMP:** odrzuca trajektorie, gdzie przewidywany ZMP wychodzi poza margines bezpieczeństwa
- **Efekt:** planista lokalny preferuje wolniejsze, bardziej konserwatywne manewry w trudnym terenie
- **Parametr:** `safety_margin_zmp` = 2–4 cm; dla schodów i pochyłości zwiększony do 5–8 cm

03

SEKCJA

Planowanie kroków i trajektorii humanoida

Footstep planning, ograniczenia, schody, trajektoria CoM



Od ścieżki geometrycznej do sekwencji kroków

1

Ścieżka bazy

Globalna trasa (x,y) lub (x,y,z) wyznaczona przez A^* ; reprezentuje ruch CoM lub miednicy

2

Wzorzec chodu

Parametry: długość kroku l , szerokość w , czas fazy T_{step} , T_{swing} ; regularne lub adaptacyjne

3

Wyznaczenie stóp

Dla każdego punktu ścieżki wyznacz cele stopy: offset lewo/prawo $\pm w/2$, orientacja = yaw trasy

4

Weryfikacja

Sprawdź długość kroku, osiągalność kinematyczną, kontakt z terenem, margines ZMP i stabilność

Parametry i ograniczenia planowania kroków

- **Długość kroku:** typowo 0,2–0,5 m; zależy od prędkości i stabilności (przy niskiej prędkości krócej)
- **Szerokość kroku:** 0,1–0,25 m; za mała = utrata stabilności, za duża = kolizja nóg
- **Orientacja stopy:** dostosowana do krzywizny ścieżki i pochylenia terenu (normal surface)
- **Strefy dozwolonego kontaktu** (foothold regions): płaskie, niegrzybowe obszary $\geq$ stopa robota
- **Kolejność kroków:** lewa–prawa naprzemiennie; podwójne podparcie $\geq$ 20% cyklu
- **Wykluczenie:** krawędzie, śliskie powierzchnie, zbyt strome pochylenie ($>20^\circ$), wąskie progi
- **Planowanie w 3D:** wymagane gdy teren ma zmienną wysokość (schody, kamienie, nierówności)

Ograniczenia kinematyczne i stabilnościowe

Ograniczenia kinematyczne

- **Zasięg nogi:** max odległość stopa–biodro $\leq l_{\max}$
- **Min. odstęp:** stopy nie mogą nachodzić na siebie
- **Zakres stawów:** każdy staw w przedziale $[q_{\min}, q_{\max}]$
- **Prędkość stawów:** $\omega_{\text{joint}} \leq \omega_{\max}$ (przepustowość aktuatora)
- **Konfiguracja singularna:** unikanie pełnego wyprostu kolana

Ograniczenia stabilnościowe

- **ZMP** wewnątrz wieloboku podparcia z marginesem
- **Capture Point** w dopuszczalnej strefie landing
- **Odchylenie tułowia** $\leq \pm 15^\circ$ od pionu
- **Prędkość CoM** ograniczona przez marginesy LIPM
- **Przy schodach:** dodatkowy margines boczny +3 cm

Planowanie na schodach i nierównościach

- **Detekcja schodów:** segmentacja chmury punktów; klasyfikacja płaskich poziomych płaszczyzn
- **Wysokość stopnia:** robot musi unieść stopę o $(h_{\text{step}} + \text{clearance})$ ponad krawędź
- **Miejsca kontaktu:** wyznaczane na środku głębokości stopnia z marginesem ≥ 2 cm od krawędzi
- **Kolejność działań:** wejście przodem – lewa noga wyżej $\rightarrow$ prawa noga dołącza, powtórz
- **Trajektoria stopy w powietrzu:** krzywa beziera nad stopniem; max wysokość = $h_{\text{step}} + 5$ cm
- **Kontrola ciała:** tułów pochyla się nieznacznie do przodu przy wchodzeniu, do tyłu przy schodzeniu
- **Zabezpieczenie:** jeśli wysokość stopnia > 25 cm lub brak miejsca kontaktu – zatrzymaj misję

Generacja sekwencji kroków (footstep planner)

```
import numpy as np

def generate_footsteps(path_xy, step_length=0.35,
                       step_width=0.18) -> list:
    """Generuje naprzemienne kroki L/P wzdłuż ścieżki."""
    footsteps = []
    left_foot = True # zaczyna lewa noga
    dist_accum = 0.0
    for i in range(1, len(path_xy)):
        dx = path_xy[i][0] - path_xy[i-1][0]
        dy = path_xy[i][1] - path_xy[i-1][1]
        dist_accum += np.hypot(dx, dy)
        if dist_accum >= step_length:
            yaw = np.arctan2(dy, dx)
            sign = 1.0 if left_foot else -1.0
            foot_x = path_xy[i][0] - np.sin(yaw)*sign*step_width/2
            foot_y = path_xy[i][1] + np.cos(yaw)*sign*step_width/2
            footsteps.append({'x':foot_x,'y':foot_y,'yaw':yaw,'left':left_foot})
            left_foot = not left_foot
            dist_accum = 0.0
    return footsteps
```

Opis: Offset $\pm \text{step_width}/2$ prostopadle do kierunku ruchu; 'left' flaga steruje naprzemiennością L/P.

Weryfikacja wykonalności kroku

```
import numpy as np

def generate_footsteps(path_xy, step_length=0.35,
                      step_width=0.18) -> list:
    """Generuje naprzemienne kroki L/P wzdłuż ścieżki."""
    footsteps = []
    left_foot = True # zaczyna lewa noga
    dist_accum = 0.0
    for i in range(1, len(path_xy)):
        dx = path_xy[i][0] - path_xy[i-1][0]
        dy = path_xy[i][1] - path_xy[i-1][1]
        dist_accum += np.hypot(dx, dy)
        if dist_accum >= step_length:
            yaw = np.arctan2(dy, dx)
            sign = 1.0 if left_foot else -1.0
            foot_x = path_xy[i][0] - np.sin(yaw)*sign*step_width/2
            foot_y = path_xy[i][1] + np.cos(yaw)*sign*step_width/2
            footsteps.append({'x':foot_x,'y':foot_y,'yaw':yaw,'left':left_foot})
            left_foot = not left_foot
            dist_accum = 0.0
    return footsteps
```

Opis: Trzy sprawdzenia: długość wzdłużna, odchylenie boczne i skręt; zwraca dict z diagnostyką

Trajektoria środka masy, a sekwencja kroków

- **CoM** (Centre of Mass) musi śledzić zaplanowane kroki przez model LIPM (Linear Inverted Pendulum)
- **Przy podwójnym podparciu:** CoM przesuwa się od poprzedniej stopy do następnej
- **Przy pojedynczym podparciu** (faza swing): CoM podąża parabolą wyznaczoną przez ZMP
- **Sprzężenie:** sekwencja kroków $\rightarrow$ trajektoria ZMP $\rightarrow$ trajektoria CoM (generator QP)
- **Weryfikacja online:** $ZMP(t) \in \text{convex hull}(\text{stopa_oparta})$ przez cały cykl kroku
- **Narzędzie:** biblioteki Choreonoid, OpenHRP, ROS2 Whole Body Controller
- **Kompromis:** krótsze, częstsze kroki = lepsza stabilność CoM kosztem prędkości ruchu

Dobór planisty do konkretnej aplikacji

Laboratorium badawcze

A* + DWA; prosta cost map; footstep planer 2D;
iteracyjna weryfikacja ZMP; MuJoCo do testów

Robot usługowy (biuro)

A* z cost map + Social DWA; detekcja YOLO;
adaptacyjne kroki; zatrzymanie przy ludziach < 1 m

Ratownictwo (gruz)

3D A* lub RRT*; footstep w 3D z height map;
MPC lokalny; konserwatywne marginesy ZMP

Środowisko zatłoczone

ORCA lub S-MPC; krótki horyzont predykcji (0,5 s);
priority queue stref bezpiecznych; niskie prędkości

Schody i poziomy

Hierarchiczny planer: globalny graf pięter +
lokalny 3D footstep; detekcja stopni z point cloud

Sport/zawody

MPC z agresywnym horyzontem; dynamiczny
chód biegowy; uproszczony footstep dla
szybkości kosztem marginesu ZMP

PODSUMOWANIE

- 01 Planowanie globalne (A^* , Dijkstra) wyznacza optymalną trasę; heurystyki i cost map sterują wyborem ścieżki
- 02 Planista lokalny (DWA, MPC, potential fields) reaguje na zmiany środowiska i przeszkody dynamiczne
- 03 Stabilność ma wyższy priorytet niż optymalność trasy – planista musi uwzględniać margines równowagi
- 04 Footstep planning tłumaczy geometryczną ścieżkę na fizyczną sekwencję kroków z weryfikacją kinematyczną
- 05 Trzy poziomy decyzji – globalny, lokalny, footstep – są sprzężone i muszą działać w spójnej pętli

Zadanie projektowe i pytania problemowe

- Dlaczego heurystyka Manhattan nie jest dopuszczalna dla siatek z ruchem 8-kierunkowym?
- Co się dzieje z polem potencjału, gdy robot wpadnie w lokalne minimum? Zaproponuj wyjście.
- Jaką wartość parametru α i β wybrałbyś dla DWA w zatłoczonym korytarzu? Uzasadnij.

Zadanie projektowe: zaprojektuj planistę kroków dla humanoida poruszającego się w korytarzu 1,5 m szerokości z napotykanymi ludźmi. Opisz: jakie dane wejściowe są potrzebne, jak wyznaczasz miejsca kontaktu stóp, jak weryfikujesz każdy krok, jak reaguje planista gdy droga jest zablokowana przez >3 s.

Bonus: zaimplementuj wygładzanie B-spline dla ścieżki zwróconej przez A* i porównaj liczbę kroków koniecznych do pokonania tej samej trasy przed i po wygładzeniu.